

Описание задачи.

Нужно разработать **ETL-процесс**, который будет ежедневно:

1. **Принимать входящие данные:**
 - Данные о транзакциях, терминалах, черном списке паспортов из файлов.
 - Данные о клиентах, счетах и картах из базы данных.
 2. **Загружать данные в хранилище (Data Warehouse) со спецификацией (STG/FACT/DIM):**
 - Временные таблицы для предварительной обработки данных (STG).
 - Основные таблицы измерений (DIM) и фактов (FACT).
 3. **Выявлять мошеннические операции и загружать по ним отчет в хранилище:**
 - Построить витрину данных (отчет с пометкой REP_FRAUD) с выявленными мошенническими операциями по заданным правилам. Витрина строится накоплением, каждый новый отчет за новый день укладывается в эту же таблицу с новым report_dt.
 4. **Автоматизировать весь процесс:**
 - Настроить ежедневный запуск ETL через планировщик задач (**cron**).
-

Описание входных данных

Ежедневно некие информационные системы выгружают три следующих файла:

1. **Список транзакций:**
 - Формат: CSV (например, **transactions_01032021.txt**).
 - Содержит данные о транзакциях за текущий день.
 - Поля: **trans_id**, **trans_date**, **card_num**, **oper_type**, **amt**, **oper_result**, **terminal**.
2. **Список терминалов:**
 - Формат: XLSX (например, **terminals_01032021.xlsx**).
 - Полный срез всех терминалов.
 - Поля: **terminal_id**, **terminal_type**, **terminal_city**, **terminal_address**.
3. **Черный список паспортов:**
 - Формат: XLSX (например, **passport_blacklist_01032021.xlsx**).
 - Содержит данные о паспортах в черном списке, начиная с начала месяца.
 - Поля: **passport_num**, **entry_dt**.

Дополнительно из БД извлекаются данные (схема info в БД):

- О клиентах (**clients**): информация о клиентах, включая паспортные данные.
- О счетах (**accounts**): данные о счетах клиентов.
- О картах (**cards**): данные о привязанных к счетам картах.

Обработка файлов

Выгружаемые файлы именуются согласно следующему шаблону:

transactions_DDMMYYYYY.txt

passport_blacklist_DDMMYYYYY.xlsx

terminals_DDMMYYYYY.xlsx

Предполагается что в один день приходит по одному такому файлу. После загрузки соответствующего файла он должен быть переименован в файл с расширением .backup чтобы при следующем запуске файл не искался и перемещен в каталог archive:

transactions_DDMMYYYYY.txt.backup

passport_blacklist_DDMMYYYYY.xlsx.backup


terminals_DDMMYYYYY.xlsx.backup

Желающие могут придумать, обосновать и реализовать более технологичные и учитывающие сбои способы обработки (за это будет повышен балл).

Хранилища

В качестве хранилища выступает ваша учебная база.

Данные должны быть загружены в хранилище со следующей структурой (имена сущностей указаны по существу, без особенностей правил нейминга, указанных далее):



Типы данных в полях можно изменять на однородные если для этого есть необходимость. Имена полей менять нельзя. Ко всем таблицам SCD1 должны быть добавлены технические поля `create_dt`, `update_dt`; ко всем таблицам SCD2 должны быть добавлены технические поля `effective_from`, `effective_to`, `deleted_flg`.

Структура хранилища

1. STG-таблицы:

- Хранят временные данные, загруженные из файлов и базы:

- `stg_transactions`
- `stg_terminals`
- `stg_blacklist`
- `stg_clients`
- `stg_accounts`
- `stg_cards`

2. Измерения (DIM-таблицы):

- Содержат справочную информацию с возможной историей изменений:

- `dim_clients`: клиенты (SCD1/SCD2).
- `dim_accounts`: счета (SCD1/SCD2).
- `dim_cards`: карты (SCD1/SCD2).
- `dim_terminals`: терминалы (SCD1/SCD2).

3. Факты (FACT-таблицы):

- Хранят события и данные о транзакциях:
 - `fact_transactions`: транзакции.
 - `fact_passport_blacklist`: черный список паспортов.

4. Таблица для отчетов:

- `rep_fraud`: отчет о мошенничестве.
-

Признаки мошенничества

По имеющимся данным на каждый день работы вашего ETL (имеющихся данных) необходимо выявлять транзакции, которые соответствуют следующим признакам:

1. Заблокированный или просроченный паспорт:

- Паспорт клиента находится в черном списке или его срок действия истек.

2. Недействующий договор:

- Операция проводится по счету, у которого истек срок действия (`valid_to`).

3. Совершение операций в разных городах за короткое время:

- Клиент выполняет операции в разных городах в течение 1 часа.
 - 4. **Попытка подбора суммы:**
 - В течение 20 минут клиент выполняет более 3 транзакций, каждая из которых меньше предыдущей, и только последняя успешна.
-

Требования к отчету

Ежедневно необходимо наполнять таблицу `rep_fraud` с данными о мошеннических операциях. Каждый следующий отчет за новый день укладывается в эту же таблицу с соответствующим `report_dt`. В отчете должны быть следующие поля:

- `event_dt`: дата и время события.
 - `passport`: номер паспорта клиента.
 - `fio`: ФИО клиента (из таблицы клиентов).
 - `phone`: номер телефона клиента.
 - `event_type`: описание типа мошенничества (например, "заблокированный паспорт", "недействующий договор").
 - `report_dt`: дата отчета.
-

Требования к реализации:

В anytask прикладывается zip-архив со следующими файлами и каталогами:

1. **SQL-скрипты (`main.ddl`):**
 - SQL скрипт создания всех необходимых таблиц для хранилища.
2. **Python-скрипт (`main.py`):**
 - Загрузка данные из файлов и базы в STG-таблицы.
 - Перенос данные из STG-таблиц в DIM и FACT таблицы.
 - Выявление мошеннических операций и запись их в таблицу `rep_fraud`.
 - Архивация обработанных файлов (переименовать файл в `.backup` и переместить в папку `archive`).
3. **Автоматизация:**
 - Настроить ежедневный запуск скрипта `main.py`, файл в формате crontab.

Результат:

- Данные за последние 3 дня загружены и обработаны.
 - Отчет о мошенничестве формируется ежедневно и дописывается в созданную таблицу с отчетами.
 - Присутствует автоматизация запуска скрипта.
-

Проверка результата.

Проверка задания состоит из нескольких частей, обязательных к одновременному выполнению.

1. Загрузка в anytask.

В anytask выкладывается zip-архив, содержащий следующие файлы и каталоги

файлы с данными	Файл, обязательный	Те файлы, которые вы получили в качестве задания. Просто скопируйте все 9 файлов.
main.ddl	Файл, обязательный	Файл с SQL кодом для создания всех необходимых объектов в базе.
main.cron	Файл, обязательный	Файл для постановки вашего процесса на расписание, в формате crontab
archive	Каталог, обязательный	Пустой, сюда должны перемещаться отработанные файлы
sql_scripts	Каталог, необязательный	Если вы включаете в main.py какие-то SQL скрипты, вынесенные в отдельные файлы – помещайте их сюда.
py_scripts	Каталог, необязательный	Если вы включаете в main.py какие-то python скрипты, вынесенные в отдельные файлы – помещайте их сюда.
main.py	Файл, обязательный	Основной процесс обработки

Имя архива – 4 буквы вашего кода с расширением .zip. Например, SIND.zip.

2. Данные в таблицах на сервере
3. Код в вашем git-репозитории.

Критерии оценки

1. Минимальный уровень (4 балла):

- Данные загружены в таблицу фактов (transactions).
- Создана и заполнена хотя бы одна таблица измерений.
- Структурированный и работающий код.
- Реализована форма SCD1.
- Найден хотя бы один тип мошенничества.

2. Максимальный уровень (10 баллов):

- Все таблицы реализованы в форме SCD2.
- Выявлены все типы мошенничества.
- Полностью автоматизированный процесс.

3. Дополнительные баллы:

- +1 за реализацию проекта в airflow
- +1 реализованы сложные и надежные решения (например, обработка ошибок)

Баллы от 4 до 10 будут ставиться в зависимости от **качества** решения. Качество будет определяться экспертно.

Правила именования таблиц.

Необходимо придерживаться следующих правил именования (для автоматизации проверки):

<CODE>_STG_<TABLE_NAME>	Таблицы для размещения стейджинговых таблиц (первоначальная загрузка), промежуточное выделение инкремента если требуется. Временные таблицы, если такие потребуются в расчете, можно также складывать с таким именованием. Имя таблиц можете выбирать произвольное, но смысловое.
<CODE>_DWH_FACT_<TABLE_NAME>	Таблицы фактов, загруженных в хранилище. В качестве фактов выступают сами транзакции и «черный список» паспортов. Имя таблиц – как в ER диаграмме.

<CODE>_DWH_DIM_<TABLE_NAME>	Таблицы измерений, хранящиеся в формате SCD1. Имя таблиц – как в ER диаграмме.
<CODE>_DWH_DIM_<TABLE_NAME>_HIST	Таблицы измерений, хранящиеся в SCD2 формате (только для тех, кто выполняет усложненное дз). Имя таблицы - как в ER диаграмме
CODE>_REP_FRAUD	Таблица с отчетом.
<CODE>_META_<TABLE_NAME>	Таблицы для хранения метаданных. Имя таблиц можете выбирать произвольное, но смысловое.

<CODE> - 4 буквы вашего персонального кода